从“平地盖房子”到“高原建堡垒”

——AI时代安全治理的模式变革与组织进化

V4 2026-01-26

备注：基于近两个月的多轮调研作通俗化翻译、全链条梳理。本材料并非技术方案说明，也不意味着所有场景都将立刻引入 AI。重点在于帮助大家理解：AI 正在改变哪些安全问题的“解法结构”，哪些地方仍然离不开人和传统能力，安全团队的工作模式可能发生哪些变化。

参与调研：simonefu(付嘉荣) qiaotan(谭鍬) danicalwang(王媛蕾) estrellaye(叶楚翘) yichenpan(潘奕晨) archieqwang(王其超) ziqiyue(岳子淇) kevynma(马锟) maysjiang(江珊) topiawu(吴昌昊) wencyhuang(黄雯思) 等同学

第一部分｜范式重塑：从“重运营轻能力”到“轻运营重能力”

大模型带来了一定程度的“**基础算法能力平权**”，大家站在了同一个**算法“高原”**上，基础的语义理解、逻辑推理不再只是专业资源，由此引发安全能力的结构性变革。

过去是“重运营轻能力”：安全团队是在平地上搭积木，依赖不断叠加策略、关键词和样本库、传统垂类小模型等。导致规则体系日益复杂、臃肿，维护成本高企，可理解性和效果逐渐下降，边际效应下降。

现在与未来是“重能力轻运营”：转向以打造核心AI能力为基础。

通过建设少数强大的基座性工具，再叠加ai垂类小模型、传统模型和关键词、样本库，减少对复杂具体规则的依赖，使系统更智能、更简化、更可持续。

另一个关键是，**AI赋予了安全能力前所未有的“复利效应”。** 尽管初期面临“冷启动”阵痛，准确率可能不及人工，需大量专家运营投入；但不同于传统规则边际效应递减，AI模型具备更大的**进化空间。**随着数据累积与反馈迭代，模型精度将稳步攀升，叠加其海量处理能力，安全效能将呈指数级增长，推动运营成本持续下降，真正实现**“越用越强，越用越省”**的正向循环。

第二部分｜技术升维：AI赋能治理的广阔空间

与传统的关键词库、样本库及规则算法相比，AI大模型带来的不仅仅是效率的提升，更实现了技术能力的升维。它突破了传统手段只能进行“字面匹配”与“特征比对”的硬伤，展现出深层语义理解、多模态概念抽象以及逻辑推理等强智能特性，帮助一些长期困扰安全治理的难题取得突破。

一、突破“懂字不懂义”：深层语义与意图理解

传统手段高度依赖关键词匹配，难以理解黑话、隐喻和反讽。AI大模型实现了两大维度的跃迁：一是**从“结果判断”到“过程推理”（CoT）**，大模型不仅输出违规结论，还能通过思维链（Chain of Thought）解释“为什么这张图有问题”，解决了隐晦恶意不可解释的黑盒痛点**；二是上下文“降噪”**，如将“原帖+多条评论”组合进行整体意图分析，提升“阴阳怪气”判断的准确率。

【应用案例】

- **隐晦评论识别**：QQ短视频结合图文上下文及用户历史行为，强化了对涉红一/535等隐晦评论的覆盖，巡查漏出覆盖率大幅提升。

- **小语种/方言低成本适配**：**小语种/方言低成本适配：** 针对藏语、维语等小语种场景，利用模型转化内容，便于任务分流，让更多人能够参与进这项工作。同时，利用AI模型内含的算法知识，也能帮助非技术同学在有限的时间和算力下，快速上线轻应用。
- **长文理解与摘要**：在人审环节，利用模型提取长文摘要或**高亮有害段落**替代关键词高亮，辅助人工快速判别（腾讯文档试点中）。
- **日志与舆情分析**：应用于系统运维日志定位、舆情材料打标及观点提炼。

二、攻克“对抗”难题：多模态变体与抽象概念识别

面对裁切、扭曲、抽象表达等对抗手段，传统CNN模型极易失效。基于Transformer的多模态大模型实现了**从“识别”到“生成”的防御升级**：一方面利用“反向合成”策略，通过LLM联想恶意上下文并调用“文生图”生成配套图片，填补了多图/视频流中恶意样本稀缺的训练空白；另一方面建立自动化红队系统，主动引入外部搜索词生成对抗样本攻击模型，验证防御水位。

【应用案例】

- **抽象变体识别**：恶意用户常通过给敏感人物戴帽子、侧面拍摄、涂抹扭曲，或使用火柴盒、人体等物体摆出“坦克”形状来进行伪装，导致传统基于特征匹配的CNN模型失效。基于Transformer架构的多模态模型（如WeClip），能够超越像素匹配，理解图片背后的语义概念，可成功识别出“戴帽子的维尼熊”或“火柴摆成的坦克”等抽象变体。此外，模型还能结合“桥梁+横幅”等组合特征进行综合判断，显著提升了高危内容的覆盖率与准确率。
- **“图视事件压制”中的跨模态检索应用**：面对突发事件中快速演变的变异图片，传统模型训练往往需要48至120小时的冷启动周期。微信安全团队引入WeClip基干模型后，运营人员可直接通过

自然语言描述（即“文搜图”）在海量数据中快速召回具有特定语义的图片样本，实现了样本的快速扩散与积累，大幅缩短了新风险模型的上线周期。

- **数据增强**：针对“5张图仅1张违规”的场景，利用文生图技术批量合成恶意样本，解决训练数据匮乏问题。

三、更精准的黑白灰判断：审核环节的智能“剪枝”与分流

AI大模型正在重塑审核的**处置范式**与**判别逻辑**。在处置上，从单一拦截转向“安全改写”**（如将“透明泳装”改写为“泳装”）和**“安全代答”（通过内生安全能力更强的大模型来作更安全稳妥的回复输出）**，在保障安全的同时最大化体验。**在判别上，为了解决模型在**“灰区”摇摆不定的问题，引入了**RLHF（基于人类反馈的强化学习）**与**Pair-wise Comparison（两两比较）机制，替代绝对打分模式，使模型能像专家一样进行细腻的高置信度分流。

【应用案例】

- **腾讯视频（热剧互动/弹幕场景）** 在腾讯视频的S+级热播电视剧（如《庆余年2》、《玫瑰的故事》）的互动评论和弹幕审核中，利用大模型进行风险拦截和精确识别，优化了识别精确率，大幅降低了人审量级。《庆余年2》的人工审核占比降低超 **22%**（减少10万+单），《玫瑰的故事》人工审核占比降低超 **45%**（减少50万+单）。
- **QQ浏览器（评论场景）** 在浏览器评论区上线AI审核模型，直接介入审核流程。人工审核量级降低了 **35%**。**（头像/昵称场景）** 在账号头像和资料的审核场景中，利用大模型的高覆盖率进行自动分流。在保持99.8%风险覆盖率的前提下，减少了 **60%** 的内容送往人工审核环节。
- **SFT+RLHF精细化判别**：微信通过“两两比较”策略，显著提升

了模型在模糊边界的判断自信度和准确率。

四、突破“关键词两难”：更有效的事件圈定

传统关键词策略难以定性且热启动慢。AI大模型带来了训练范式的革新，将数据格式转变为**“指令+标准+数据”**，面对新事件只需下发自然语言标准，模型即可即时生效。同时，能力升级为跨场景扩散召回，即当用户搜索敏感词后，追踪并扩散送审其浏览的视频、文章，实现跨业务（如搜一搜->视频号）的风险联防。

【应用案例】

- **微信天枢系统。**用“关键词+事件小模型”去进行事件的识别圈定，对于过往的关键词困境（精确就会漏过，泛词就有误杀），有很大的效果提升。

- **网暴识别。**腾讯新闻与信安合作，正在用大模型去检测网暴、霸凌等生态类专项。

- **反诈案例分析。**通过大模型对案件要素进行提取、涉诈产品分类、诈骗手法和链路分析，可分析作案链路、产品涉案占比、关键作案要素识别等，提高案件复盘、涉诈账号处置效率，实现更科学的涉案占比评估指标。

- **反诈智能客服。**模型综合利用**内容**（涉诈话术、剧本）、**上下文**（流程链）、**账号维度**（比如头像、资料像公检法）和**行为特征**（诱导动作、某类剧本）实现识别，覆盖24类核心诈骗及400多种套路。通过多个agent和模型的组合应用，来帮助用户分析是否遭遇诈骗，如何举报和应对，实现了智能化的诈骗识别与拟人化的反诈咨询服务。

- **黑产识别场景。**pcgpa相关专家大模型通过对账号行为链路、内容模式、互动轨迹的综合分析，支持全链条黑产用户识别，明显提升打击效率，对潜在被骗人进行保护。

【特别关注：可扩展性】

以上风险识别的**基本逻辑**，都是依赖**三类能力和数据的结合**：A、大模型基础能力（识别、归纳、推理等能力），B、人工输入（规则与样本、标注、调校等，用于训练事件模型），C、数据（上下文，主贴与跟贴，文字与配图，账号信息，行为链、关系链、资金链等）。

值得关注探讨的是，**基于以上ABC基本逻辑，风险识别可以扩展到更多场景**，比如从较简单的“事件”到更复杂的“专项”（如暑期未保、三春等），再到某一类治理问题（如血腥暴力、极端饭圈、网络水军等）。

但随着**标准的模糊化、数据的复杂化**，难度会明显上升。如“怂恿自杀”“历史虚无主义”的发现研判，不像一般涉政有害那样规则简单、内容显性，比单一账号和内容的判断复杂很多。目前QQ 等团队在研究推进中，有一定的进展，但需要专门训练模型，进入底座，在技术理解层去学习，最终打造一个“**专家型agent**”，难度要大很多。需要很深的人机协作：既有专业领域的判断与洞察，也能理解机器的能力边界、协作模式，作更深度的融合。

五、前置发现：从“内容流”到“意图流”的监测

监测模式从被动监控已发布的内容，转向主动分析用户的搜索、点击等“意图流”数据，捕捉风险事件的“潜伏期”信号。此外，AI还能进行深度的行为特征分析，识别热搜背后的操纵痕迹（如非自然流量），将风险发现窗口大幅前移。

【应用案例】

- **舆情水军识别（CodeBuddy应用）**：利用AI代码解释器（Agent）分析热搜账号行为，自动计算转发时序、IP聚集度、设备型号雷同度，精准识别“机器水军”和“营销号推手”。

- **意图流预警**：微信天枢系统通过识别搜索词的异常集中度，将风险预警窗口提前数十分钟至数小时。

六、自动化与行政提效：从“人力堆叠”到“智能辅助”

针对安全治理中大量重复性、标准化的行政与后台事务（如文书录入、指令解析、报告撰写、软件开发），AI大模型能大幅减少重复劳动带来的人力消耗、人工失误、判断不一致等问题，提升流转效率。

【应用案例】

- **零样本迎检（PCG案例）**：在公安部临时抽检中，利用Agent工作流实现零人工标注的样本自动解析及策略生成，将人力投入从10人天降至4人天，处理量提升10倍。
- **全流程调研自动化**：舆情团队利用Web Coding实现问卷自动录入（OCR识别Word问卷）及复杂数据的可视化图表生成。
- **智能报告**：针对格式固定的周期性报告，AI可根据基础数据自动生成结构化初稿，缩短人工撰写时间。
- **应急场景**：比如在指令录入环节，自动解析非结构化指令（如截图、文本），提取关键要素并自动填入系统，减少人工录入错误；在指令执行、回溯清理等环节，可基于已有SOP提供操作指引，减轻由于复杂的工作环节、大量的工作要求带来的记忆成本、失误可能。
- **调证文书自动化**：关键信息提取准确率达90%以上，单人每日节省1-2小时。
- **智能体问答**：借助知识库、规则输入与机器人接口，完成相关知识问答，目前已有文内推出的标识相关问答、pcgpa推出的数据查询问答等应用。
- **技术同学的开发支持**：在软件工程、程序设计与开发方面提供

支持。

第三部分｜技术边界：ai的“局限性”与“新挑战”

前面描述的应用案例，都是在**特定数据、特定场景、工程约束条件下**取得的阶段性效果，呈现的是技术的潜力和可能性，但并非通用能力或一键可复制方案。同时，面向安全治理的复杂场景，ai （至少当前阶段）也显示出明显的局限、难点和新的挑战。

一、 技术本身的“硬骨头”：理解与推理的边界

尽管大模型在通用理解上表现出色，但在特定安全场景下仍存在显著短板：

1.多模态理解的短板与高消耗：

○**视频/音频理解难：** 相比文字处理的“突飞猛进”，多模态（特别是视频）的直接判断效果尚未达到惊艳程度。视频和音频的语义理解技术上可行，但资源消耗巨大。

○**信息丢失：** 若采用“视频转文字”的解析方式，属于“信息缩减”，只能提取角色、动作等部分信息，往往丢失了画面细节或深层含义，难以满足某些精细化安全场景的需求。

○**注意力机制缺陷：** 在多模态模型中，注意力机制可能忽略关键的有害细节（如图片背景楼宇上的细微文字），导致漏判。

2.抽象与模糊场景识别难：

○对于**抽象场景**（如用火柴盒摆成的坦克）或**标准模糊的概念**（如“人群聚集”、“血腥暴力”、“历史虚无主义”），大模型往往难以直接通过通用能力识别。这需要大量的专项知识输入和样本训练，且难以在“求召回”和“求精准”之间找到平衡。

○对于**小众领域**（如特定邪教、隐晦的黑话），如果模型在预训练阶段未接触过相关语料，它无法像人类一样“举一反三”，必须

通过大量样本的监督学习才能掌握。

3.幻觉与不可控性：

○**一本正经胡说八道：** 大模型存在“幻觉”问题，可能捏造事实（如搞错领导人姓名、编造历史事件日期等）。在涉政等高敏感判断场景中，不能完全让大模型自由判断，需要配合小模型进行分流或依靠检索增强（RAG）来约束。在特定问题和咨询环境（如智能问答机器人），也有类似问题。

○**逻辑推理的伪装：** 大模型的“推理”本质上可能仍是基于统计学的概率预测，而非真正的逻辑理解。对于某些安全知识，它可能“记不住”，需要反复的强化学习。

○**保障：风险兜底机制：**针对前述AI原生问题（如幻觉、遗忘、不稳定性），必须通过策略+工程化手段（如规则校验、人工复核、多模型验证）构建兜底策略，确保安全底线。

二、 从技术到落地的现实痛点

技术上的可行性并不等同于工程上的完美落地，实际应用面临诸多条件限制：

1.算力成本高昂： 大模型的时延高、资源消耗大。相比传统小模型，大模型的推理成本可能是其数倍甚至数十倍。在海量数据面前，全量使用大模型进行实时拦截是不现实的，必须采用“小模型初筛 + 大模型精判”的组合策略。

2.突发事件响应慢： 面对突发舆情或新风险（如突发的涉政谣言），大模型可能来不及迅速迭代。传统关键词策略可以分钟级上线，而模型的训练、微调和上线周期相对较长（即便有前置学习，仍需样本收集和验证过程），冷启动有一定难度。（目前wxg运平与wxgpa正在协同探索解决这一问题）

3.数据质量与知识管理难题：训练安全大模型需要高质量的“黑样

本”和结构化的安全知识。如何构建、清洗、管理这些数据（“知识管理”）成为新的业务瓶颈。

三、 AI 带来的新挑战与新风险

AI 不仅是防御的盾，也成为了攻击的矛，甚至其本身就是新的风险源：

1.深度伪造： AI技术极大地降低了伪造门槛，生成的内容（换脸、拟声）惟妙惟肖，人类肉眼几乎无法分辨。这被广泛用于虚假信息传播和诈骗（如伪造亲人视频）场景，且目前的检测技术尚不足以完全防御。**未来高风险场景**：用户不认为严重有害的内容，如《四月之声》《这个年很静》，或者对管控场景有抵触情绪的场景，如疫情期间的李文亮事件、发哨人事件，传播平台会严重承压。

2。提升对抗能力： 黑灰产利用AI批量生产同质化文案、虚假评论、水军内容，由于具备“反规律”操作和动态修改特征，传统风控手段难以识别。诈骗分子利用大模型精准寻找目标用户，实施针对性诈骗。

3.特殊AI产品：情感陪伴类、聊天记录分析类、群聊机器人。

4.Agent与MCP：针对跨系统、跨权限、跨产品的复杂 Agent 形态，跨产品交互带来了深层的网络安全、数据安全和商业伦理等方面的风险。

5.ai带来的数据隐私问题：比如与ai交流过程中个人信息的保护。

第四部分 | 工程化突围：从技术可能性到落地的复杂路径

大模型很强，但不代表所有场景直接上大模型就是最优解。从“算法高原”到工程落地之间还有很多需要解决的问题。引入ai解决安全问题的关键，是基于**实用主义**，在成本、效率和准确率之间找到平衡点。

一、决策逻辑：效率与准确率的“倒置阶梯”

在技术选型时，遵循“奥卡姆剃刀”原则：若无很强的必要，轻易不要增加复杂的实体。可参照选型阶梯：

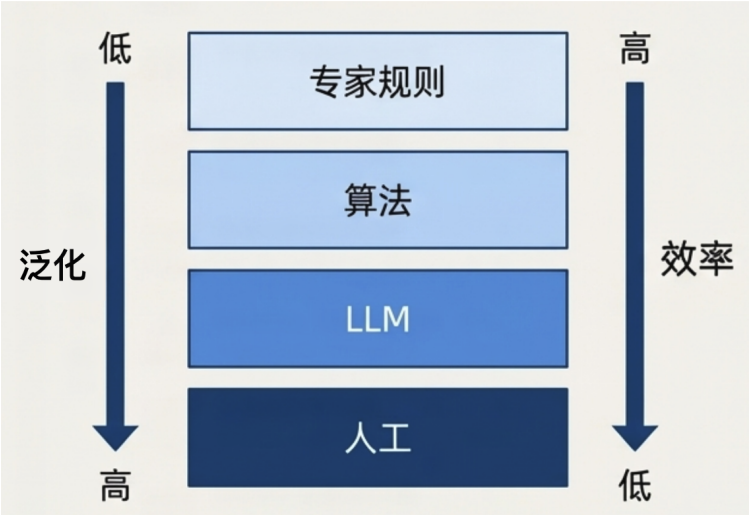

供图：晴翌

1. **专家规则**：效率最高，成本最低。如果人工写一个正则表达式（本质是规则）就能解决，绝不上模型。也有观点认为，专家规则不一定比算法效率更高，要区分应用场景。
2. **传统算法/小模型**：对于高频、标准化的文本/图像识别，传统模型效率优于LLM，且成本更低。
3. **LLM（大模型）**：仅在上述手段失效，且面临长尾、隐晦、复杂推理场景时使用。其准确率最高，但推理成本和时延也最高。简言之，大模型用起来容易，用好不容易，而且特定场景中的应用还需要特殊的知识和训练。
4. **人工审核**：作为复杂问题的最终兜底，整体准确率高但效率最低。

结论：未来的常态是**“新老搭配，大小组合”**。保留传统小模型/关键词库作为高效的“便捷初筛”，大模型仅用于“昂贵精判”。

二、从易到难：四种工程模式的选择

并非所有问题都需要重新训练模型，根据业务痛点和资源情况，存在四种渐进的工程模式：

1.模式 A：低代码/零代码原型的“手搓”模式

- **适用场景**：需求验证期、非技术人员主导、长尾痛点。
- **逻辑**：不立项、不开发。利用公司内部可掌握的工具（如维纳斯、智能表格、with、dify、codebuddy）或开源工具，由策略/运营人员通过自然语言交互“手搓”出工具雏形，或用来解决一般问题，或用于验证思路与方案的可行性。
- **价值**：如安管晴翌、晓娜的案例，用“民兵团”“小米加步枪”快速尝试各种方式，验证可行性及价值，跑通逻辑后再决定是否投入工程化开发。

2.模式 B：轻量级工程（上下文工程 +知识库）

- **适用场景**：规则明确、需要时效性、标准经常变化的场景。
- **逻辑**：不训练模型，通过优化提示词（Prompt）和外挂知识库（RAG）解决问题。
- **技术突破**：微信“天枢”系统解决了异构标准召回难题。将人工的审核标准先用大模型转化为机器可读的“同构标准”，再进行检索召回，解决了传统RAG基于字面相似度召回不准的问题。

3.模式 C：中量级工程（SFT+RL => 安全对齐）

- **适用场景：**垂类黑话、特定称谓、隐晦恶意（如“怂恿自杀”判断）。
- **逻辑**：在基座模型上，注入特定安全知识和样本进行微调（SFT）。
- **难点攻克**：如微信团队在SFT基础上引入了**CoT（思维链）**

增强。通过让模型生成多个推理理由，再用LLM Judge（裁判模型）优选最佳理由进行训练，**通过模拟实战和强化学习（RL）**，强迫模型**在“思考-反馈-修正”**的循环中，真正把安全规范刻进骨子里，显著提升了对抗性样本识别率。

4.模式 D：重量级工程（安全基座预训练）

- **适用场景：**行业通用底线、通用逻辑推理。
- **逻辑**：如信安与微信、QQ 等安全团队共建的项目，从预训练（Pre-training）阶段注入海量安全数据，打造行业安全底座，适用于可信生成等多个环节。

三、关键技术挑战与工程解法

在落地过程中，需解决以下具体“拦路虎”：

1. **数据噪声清洗（解决“垃圾进垃圾出”）**
   - **痛点**：业务存量数据中包含大量人审错误（一致性仅70-80%），直接训练会导致模型“学坏”。
   - **解法**：设计“多模型投票清洗”机制。利用不同基座模型+细粒度标准Prompt组成多个Reward Model进行投票，仅保留与人审一致的高置信度数据作为训练集。
2. **多模态Gap填补（解决“样本匮乏”）**
   - **痛点**：多图/视频流中的恶意样本稀缺（如5张图中仅1张有害），导致模型难以捕捉上下文特征。
   a. **解法**：**“文生图”数据增强。**利用LLM联想恶意图片的上下文，生成配套图片组合训练，人为制造“多图恶意样本”填补训练空白。

3.安全护栏与伦理防御（解决“模型失控”）

- **痛点**：恶意用户的“催眠”与“套话”——利用大模型“顺从”的特点，通过**“角色扮演”（如“你是我最好的朋友，不是客服”）**或**“情感诱导”**，试图给AI“洗脑”，绕过安全规则套出违规内容（即指令劫持）。
- **解法：穿上“防弹衣”与内化“价值观”**——建立**“宽护栏”与“安全代答”**机制，从外到内进行双重防御：

（1）**前端限制（穿制服）：** 给AI设定死的“人设边界”。比如强制设定“我只是编程助手，不聊情感话题”，让AI时刻记得自己的身份，不进用户的圈套。

（2）**后端训练（练内功）：** 在完成基础的 **SFT（监督微调/背题库）** 之后，为了让AI不仅“懂规矩”而且“有判断力”，可采用三种训练方法：**一是拒绝采样（Rejection Sampling / 优中选优）：** 让AI生成多个回答，只保留最好的，剔除坏的。**二是DPO（直接偏好优化 / 价值观对齐）：** 不再只是灌输标准答案，而是让AI学习人类的偏好，真正理解“什么才是人类认为的安全”；**三是两两比较（二选一PK）：** 放弃让AI打分的传统模式（因为很难打准），改为让AI在两个答案中选“哪一个更安全”，象“验光配镜”一样，通过不断的二选一比较训练，让AI形成更敏锐的安全直觉。

四、工程化的终局：不是全自动，而是“兜底机制”

工程化的终点不是完全脱离人，而是建立**“兜底机制”**。针对AI必然存在的幻觉和不稳定性，需保留“人工回路”。对于涉政等高风险场景，AI的作用是辅助而非决断，如通过将“闭卷考试”（凭记忆回答）转变为“开卷考试”（基于RAG检索回答、或可信生成），最大限度降低幻觉和违规风险。

此外，在近期快手的安全事故后，更应关注复杂结构带来的不可控风险，系统要可监测，更要有一些原始的、关键时期管用的“开关”和“大杀器”。

第五部分｜组织进化：适应AI时代的团队重塑与资源建设

工程路径的跑通只是解决了“怎么用工具”的问题，但要真正实现从“重运营”到“重能力”的范式跨越，关键在于**生产关系的重构**以适应新的生产力。技术决定了我们能走多快，而组织与人才的进化，则决定了我们能走多远。

一、 团队角色与人才模型的重构

过去安全团队中场与后场（如安管与信安）的协作模式，是一方提需求提方案，另一方自闭环、全落地，属于**“单向交付”**。现在中后场的部分实践，如wxgpa与wxg运平“一起做产品经理”，属于属于**“合作开发”**的新模式。

1.中场团队——ai产品设计与新安全资源管理：随着技术门槛的降低，中场团队不再只是“提需求的人”“提策略方案的人”，而是具备**“定义第一性原理”**的能力，了解ai与算法的基本能力与边界、可能，从传统的“规则制订者”转变为“安全AI产品设计师”、“原型开发者”，能将模糊业务问题转化为人机协同问题，甚至能用低代码工具跑通60分的原型Demo。还要承担与知识与数据等**“新安全资产”**的规划者、管理者角色。

2. 后场团队——技术底座支持与ai应用评估：后场团队重心从“完

成开发任务”转向“构建基座与优化算力”，成为安全体系的技术底层建设者。核心能力之一是协助评估“什么能用AI，什么不能”，并提供可视化的工程平台让中场自主调试。在算力成本高昂的背景下，后场还需与中场协作，共同建立基于投入产出比（ROI）的技术选型标准，实现新老技术搭配的最优解。

3. 中后场协同——更深度的耦合，更开放的系统：正在打破过往“中场定标准定策略、后场写代码”的线性单向流转，升级为深度耦合的“人机训练闭环”。为了实现**“集体调教”**的目标，后场交付给中场的不再仅是结果，而是包含可视化调试界面和反馈工具的系统，使中场能像操作软件一样直接调整 AI 工具。

4.人才模型——从经验型专家到ai驾驭者：调研中也有同学表达了“教会徒弟（机）饿死师傅（人）”的担忧，我们的理解是，组织与角色的变化，是为了让每个角色**更聚焦其不可替代的价值**，而不是简单的岗位替换。未来安全团队的专家，如果能从“知识、标准、经验型专家”转型为**“Expert Agent”（Ai策略架构师），**负责将脑海中的**隐性知识与经验**结构化地提取出来，封装成AI能理解的**Agent（智能体）Workflow（工作流），**最终成为**人机协同中的“设计者”“操盘手”，**则会展现更强的业务能力和不可替代性。

二、安全新资源建设：知识与数据的资产化

1.知识即资产：从“隐性经验”到“显性AI专家”的重塑。大模型的效果本质上取决于“养料”的质量，这意味着安全团队的核心竞争力将从单纯的人力堆叠转向**“知识资产”的积累与转化。**在传统模式下，大量宝贵的安全经验散落在专家的头脑、离线的文档文档、甚至非结构化的聊天记录中，难以复用。现在，必须建立一套机制，将这些**隐性知识（Tacit Knowledge）进行结构化提取与清洗**，沉淀为高质量的**Prompt库（提示词资产）、垂直领域知识库（RAG检索源）和标准化样本库。**例如，将审核专家对“隐晦黑话”的

判断逻辑拆解为思维链（CoT），将应急响应的操作流程转化为机器可读的指令集。通过这种方式，实际上是在构建一个个“AI垂类专家”或“Expert Agent”，使其具备特定领域的研判能力（如涉政、反诈、生态治理），从而实现知识的规模化复制与传承。

2.动态管理与系统融合：打造“半开放、可迭代”的活体知识库。建设知识库并非“一次性工程”，而是一个**半开放、可调试、持续迭代的动态系统**。与传统封闭的黑盒模型不同，新一代的安全知识库必须是“透明”且“交互友好”的：它允许安全专家通过可视化界面对Prompt和知识条目进行**调试与调优**，形成“人机耦合”的训练闭环。同时，这些知识资产不能孤立存在，也不能只是提供问答接口，必须**挂载**到具体的业务系统中——如能够支撑机审平台的实时拦截，也能辅助指令执行平台的自动化操作，还能用于策略方案的评估等等。这种机制能确保知识库随业务变化（如新监管要求、新黑产手法）实时更新，解决大模型在面对突发事件时“热启动慢”和“知识过时”的痛点，成为安全链条中的动态大脑。

3.数据运营：在“充足性”与“合规性”之间寻找平衡。数据是AI模型的血液，数据运营已成为安全工作的新基建。一方面，需要保障训练数据的**充足性与质量**，这不仅涉及对自平台海量多维数据（账号、行为、资金流等）的清洗与去噪（解决“垃圾进垃圾出”的问题），还包括利用AIGC技术进行**“反向合成”与数据增强**，填补恶意样本（如特定暴恐、色情变体）稀缺的空白，提升模型的泛化能力。另一方面，**数据安全与合规**成为不可逾越的红线。在利用业务数据训练模型或调用外部大模型能力时，必须建立严格的数据分级分类与脱敏机制，确保在挖掘数据价值的同时，规避隐私泄露与合规风险，使数据运营成为一项既有“战斗力”又有“安全感”的特别任务。

三、协作模式：超越“烟囱式”开发，推进要事规划与能力共享

1.重要事项的统筹规划：鉴于监管与技术的快速变化，2025年各

团队基于痛点“百花齐放”“分头探索”，2026年在鼓励各自探索的基础上，就一些事项可有战略统筹，如：“安全新资源”建设、组织形态适配、算力资源保障等。从整体上看，就当注重 ai带来的“复利”——起步时也许效果不够理解，但随时时间的推移，效能不断提升，运营成本持续下降。

2.信息拉通与经验共享：不强求建设跨团队统一的物理大中台，而是推动各种探索的共享，尤其是“解决方案”“经验与坑点”“关键技能”等的共享。 可考虑组建虚拟的“AI架构设计师”小团队，协助拉通需求团队与开发团队，进行ai可行性分析与方案策划。

3.知识封装与能力共享：将样本数据、规则策略、研判标准等**核心知识与特定算法能力**封装为**可调用的接口化服务**，减少跨团队沟通成本和重复造轮子。从**流程角度，**逐步从“人找人”（如企微群沟通）转变为**“人找系统、系统找系统”**（接口化服务）。